

Rapport de Projet: Régression Logistique pour la Classification de Chiffres Manuscrits

Lilian NOACCO
Basile LE THIEC
2A Alt IR

1 Introduction

Ce rapport détaille l'implémentation d'un classifieur d'images *from scratch* en utilisant la régression logistique multi-classes. L'objectif est de classer les images de chiffres manuscrits de la base de données 'digits' fournie par scikit-learn. Ce document couvre la théorie mathématique, la mise en oeuvre, la comparaison avec l'implémentation de référence de scikit-learn, et une analyse des résultats obtenus.

2 Théorie Mathématique

2.1 Régression Logistique Multi-classes

La régression logistique est un modèle linéaire utilisé pour la classification. Pour un problème à K classes, nous cherchons à modéliser la probabilité qu'une entrée $\mathbf{x}$ appartienne à la classe k : $P(y = k|\mathbf{x})$.

Le score (ou logit) pour chaque classe k est calculé comme une fonction linéaire de $\mathbf{x}$:

$$z_k = \mathbf{x} \cdot \mathbf{W}_k^T + b_k \quad (1)$$

Où:

- $\mathbf{W}_k$ est le vecteur de poids pour la classe k .
- b_k est le biais pour la classe k .

2.2 Fonction Softmax

Pour convertir ces scores en probabilités, nous utilisons la fonction Softmax, qui garantit que la somme des probabilités pour toutes les classes est égale à 1.

$$P(y = k|\mathbf{x}) = \text{softmax}(z)_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)} \quad (2)$$

Pour des raisons de stabilité numérique, on soustrait généralement le score maximum avant de passer à l'exponentielle : $\exp(z_k - \max(\mathbf{z}))$.

2.3 Descente de Gradient et Fonction de Coût

L'objectif est de trouver les paramètres $\mathbf{W}$ et $\mathbf{b}$ qui minimisent une fonction de coût. Pour la régression logistique multi-classes, on utilise la fonction de coût d'entropie croisée (Cross-Entropy Loss):

$$J(\mathbf{W}, \mathbf{b}) = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} \log(p_{i,k}) \quad (3)$$

Où N est le nombre d'échantillons, $y_{i,k}$ est 1 si l'échantillon i appartient à la classe k (encodage one-hot), et $p_{i,k}$ est la probabilité prédite.

Nous utilisons la descente de gradient pour minimiser cette fonction. Les gradients sont :

$$\nabla_{\mathbf{W}_k} J = \frac{1}{N} \sum_{i=1}^N (p_{i,k} - y_{i,k}) \mathbf{x}_i \quad (4)$$

$$\nabla_{b_k} J = \frac{1}{N} \sum_{i=1}^N (p_{i,k} - y_{i,k}) \quad (5)$$

Les poids sont mis à jour comme suit, où η est le taux d'apprentissage:

$$\mathbf{W}_k := \mathbf{W}_k - \eta \nabla_{\mathbf{W}_k} J \quad (6)$$

$$b_k := b_k - \eta \nabla_{b_k} J \quad (7)$$

2.4 Régularisation L2 (Bonus)

Pour prévenir le surapprentissage, nous avons ajouté une régularisation L2 (Ridge) qui modifie la fonction de coût:

$$J_{\text{reg}}(\mathbf{W}, \mathbf{b}) = J(\mathbf{W}, \mathbf{b}) + \frac{\alpha}{2} \sum_{k=1}^K \|\mathbf{W}_k\|^2 \quad (8)$$

Le gradient pour les poids est alors modifié :

$$\nabla_{\mathbf{W}_k} J_{\text{reg}} = \nabla_{\mathbf{W}_k} J + \alpha \mathbf{W}_k \quad (9)$$

3 Implémentation et Résultats

Le script `main.py` met en œuvre ce qui suit:

- **Traitement des données:** Chargement du jeu de données, encodage one-hot et division en ensembles d'entraînement et de test.
- **Implémentation from scratch:** La classe `CustomLogisticRegression` utilisant la classe `GradientDescent` développée en TD1 pour la descente de gradient.
- **Comparaison:** Le modèle custom est comparé à `LogisticRegression` de scikit-learn.
- **Bonus :** Une version avec régularisation L2 a été implémentée.
- **Analyse des paramètres:** Étude empirique de l'influence du taux d'apprentissage et de la régularisation.

3.1 Résultats Obtenus

- **Modèle Custom (sans régularisation):** Accuracy = 97.50%
- **Modèle Scikit-learn:** Accuracy = 97.50%
- **Modèle Custom (avec régularisation L2, $\alpha = 0.0$):** Accuracy = 97.50%

Notre implémentation atteint des performances identiques à scikit-learn. La régularisation L2 n'a pas amélioré les performances dans ce cas, le meilleur paramètre de régularisation trouvé étant $\alpha = 0.0$.

3.2 Matrices de Confusion

3.3 Réglage des Hyperparamètres par Validation Croisée

Pour optimiser les hyperparamètres (`learning_rate` et α), nous avons utilisé une validation croisée à 3 plis. Les meilleurs paramètres trouvés sont `learning_rate` = 0.01 et α = 0.0, avec un score de validation croisée de 96.24%.




Figure 1: Matrice de confusion du modèle personnalisé

3.4 Test sur MNIST

En complément, nous avons testé le modèle sur un sous-ensemble de 10 000 échantillons du jeu de données MNIST. L'accuracy obtenue est de 86.65%, démontrant la généralisation du modèle à des données plus complexes.

4 Analyse et Réflexion

4.1 Interprétation des Coefficients

Les poids ($\mathbf{W}$) appris par le modèle peuvent être visualisés comme des images. Ces images représentent les 'templates' que le modèle a appris pour chaque chiffre.

4.2 Analyse des Erreurs

L'analyse des images mal classées montre souvent des chiffres ambigus ou mal formés, ce qui explique les erreurs du modèle linéaire.

4.3 Prise de Recul

- **Difficultés:** Assurer la stabilité numérique de la fonction softmax.
- **Limites:** La régression logistique est un modèle simple. Des modèles plus complexes comme les réseaux de neurones convolutifs (CNN) sont généralement plus performants pour cette tâche.
- **Paramètres:** Le choix du `learning_rate` et de `max_iter` est crucial et nécessite une validation croisée pour un réglage optimal.

5 Conclusion

Ce projet a permis de mettre en pratique la théorie de la régression logistique. L'implémentation *from scratch* a donné d'excellents résultats, atteignant les mêmes performances qu'une librairie de référence.




Figure 2: Matrice de confusion du modèle scikit-learn

La régularisation L2 n'a pas été nécessaire dans ce cas pour atteindre l'optimal, mais reste un outil important pour prévenir le surapprentissage sur des jeux de données plus complexes.




Figure 3: Coefficients appris pour chaque classe (visualisation des poids comme images 8×8).




Figure 4: Exemples d'images mal classifiées (prédiction vs étiquette réelle).